

Tris

# **Chapitre 8**

**Tris** 

Savoirs et compétences :

Tris.

1	Introduction et objectifs	2
2	Tri par insertion	2
3	Tri rapide (ou « quicksort »)	3
4	Tri fusion – <i>Merge sort</i>	5
5	Dans Python : sort et sorted	6
6	Conclusion et méthodes dans Python	6
7	OCM .	7

### 1 Introduction et objectifs

Objectif Un algorithme de tri est un algorithme permettant d'organiser une liste d'éléments selon un ordre fixé. On peut dire que les éléments à trier feront partie d'un ensemble E muni d'une relation d'ordre total noté  $\leq$ .

Les ensembles  $\mathbb{N}$ ,  $\mathbb{R}$ ... sont munis de l'ordre  $\leq$ .

L'ensemble des chaînes de caractères peut être muni de l'ordre lexicographique (ordre du dictionnaire). Ainsi en Python, 'a'<'b', 'aa'<'b', 'A'<'a' (les lettres majuscules sont avant les lettres minuscules).

Les principales capacités développées ici sont :

- comprendre un algorithme de tri et expliquer ce qu'il fait;
- s'interroger sur l'efficacité algorithmique temporelle d'un algorithme;
- programmer un algorithme dans un langage de programmation moderne et général.

**Définition Effet de bord** On dit qu'une fonction est à effet de bord lorsqu'elle modifie une variable en dehors de son environnement local. C'est par exemple le cas lorsqu'on donne une liste (objet mutable, passé par référence) comme argument d'une fonction.

Conséquence sur les algorithmes de tri : une fonction de tri ne renvoie rien la plupart du temps (on peut donc l'appeler une procédure). La liste passée en argument en entrée sera triée et cela, même en dehors du scope de la fonction.


**Définition Tri en place** Un tri est effectué en place lorsque la liste à trier est modifiée jusqu'à devenir triée. Dans le cas contraire, la fonction de tri pourra renvoyer une novelle liste contenent les mêmes éléments, mais triés.

**Définition Tri stable** Un algorithme est dit stable si les positions relatives de deux éléments égaux ne sont pas modifiées par l'algorithme : c'est-à-dire que si deux éléments x et y égaux se trouvent aux positions  $i_x$  et  $i_y$  de la liste avant l'algorithme, avec  $i_x < i_y$ , alors c'est également le cas de leurs positions après l'algorithme.

**Définition** Tri comparatif Un tri est dit comparatif lorsqu'il s'appuie uniquement sur la comparaison deux à deux des éléments de la liste et pas sur la valeur ce ces éléments.

■ Exemple Un algorithme comparatif (à opposer au non-comparatif comme le tri baquet ou par paquet) est basé sur des comparaisons successives entre les données pour déterminer la permutation correspondant à l'ordre croissant des données. On va chercher ici à évaluer la complexité théorique des tris comparatifs en se basant sur le nombre de comparaisons.

Cet algorithme correspond au fonctionnement du tri insertion que nous verrons plus loin:



### 2 Tri par insertion

### 2.1 Principe

**Définition Principe du tri par insertion** Le **tri par insertion** est le tri que l'on effectue naturellement, par exemple pour trier un jeu de cartes. On trie les premières puis à chaque nouvelle carte on l'ajoute à l'ensemble déjà trié à la bonne place. Ce tri s'effectue en place, c'est-à-dire qu'il ne demande pas d'autre tableau que celui que l'on trie. Son coût en mémoire est donc constant si on ne compte pas la place occupée par les données.

### 2.2 Implémentation

- On stocke les données dans un tableau L entre les indices 0 et n-1.
- On utilise deux variables notées *i*, *j* et une variable clef (la clef) du même type que les données de la liste.
- On réalise une première boucle qui va permettre de parcourir tous les éléments L[i] du tableau à trier. Chacun de ces éléments sera alors successivement la clef.



- La deuxième boucle (while) va nous permettre pour chaque valeur de la clef de tester successivement les valeurs déjà triées jusqu'à trouver une valeur inférieure. On aura ainsi déterminé la place de la clef.
- A chaque fois qu'une valeur est plus grande que la clef on la décale vers la droite pour laisser la place d'écrire la clef. Dès que l'on arrive sur une valeur inférieure on a trouvé la bonne place pour écrire la clef.

```
def tri_insertion(L:list) -> list:
    """
    Tri par insertion d'une liste d'entiers L.
    """
    n = len(L)
    for i in range(1,n):
        # Invariant : en entrée de boucle L[0:i-1] est triée.
        j = i
        v = T[i]
        while j>0 and v<L[j-1] :
        L[j] = L[j-1]
        j = j-1
        L[j] = v
        # Invariant : en fin de boucle L[0:i] est triée.
    return L</pre>
```

### 2.3 Terminaison

Pour la boucle while, la quantité j est un variant de boucle. En effet :

- avant d'entrer dans la boucle, j est une quantité entière strictement positive;
- j est décrémenté de 1 à chaque itération, donc j décroit strictement à chaque itération.
- j est donc un variant de boucle.

La boucle for termine au bout de n-1 itérations. L'algorithme de tri par insertion termine donc.

### 2.4 Correction

Montrons que la propriété L [0:i] est triée est un invariant de boucle.

Initialisation En entrant dans la boucle : i=1; donc L [0:1] ne contient qu'un élément. L [0:1] est triée.

**Hypothèse**: considérons qu'au début de l'itération i, L[1:i-1] est triée.

Montrons qu'à la fin de l'itération i, L[1:i] est triée.

- v = L[i] est la valeur à insérer dans L[0:i-1].
- ou bien v>=L[i-1], on n'entre pas dans la boucle while et L[i]=v; donc L[0:i] est triée.
- ou bien v<L[i-1] et on entre dans la boucle while.j décrémente alors et tous les éléments sont « décalés vers la droite » jusqu'à ce que v>=L[j-1]. On insère alors v en L[j].

À la fin du n-1 tour de boucle, L [0:n] est donc triée.

### 2.5 Complexité

Propriété Complexité

La complexité est dans le pire des cas quadratique :  $C(n) = \mathcal{O}(n^2)$ .

La complexité est dans le meilleur des cas linéaire :  $C(n) = \mathcal{O}(n)$ .

L'efficacité du tri par insertion est excellente lorsque le tableau est déjà trié ou « presque trié »  $(C(n) = \mathcal{O}(n))$ . Il surpasse alors toutes les autres méthodes de tri qui sont au mieux en  $\mathcal{O}(n \times \ln(n))$ .

Au vu de notre algorithme, le pire des cas que l'on peut rencontrer est celui où la liste L est triée dans l'ordre décroissant. En effet, dans ce cas, à l'itération i, la boucle while devra être réalisée i fois.

Comptons le nombre de comparaisons j >0 réalisées par l'algorithme pour une liste de n éléments :

- à l'itération 1 : il y a 2 comparaisons;
- à l'itération 2 : il y a 3 comparaisons;
- ..
- à l'itération n-1: il y a n comparaisons.

Au final le nombre de comparaisons est égal à  $C(n) = 2 + 3 + ... + n = \sum_{i=1}^{n} (i) - 1 = \frac{1}{2}n(n+1) - 1 = \mathcal{O}(n^2)$ .

### 3 Tri rapide (ou « quicksort »)

### 3.1 Principe

**Définition Tri rapide L'algorithme de tri rapide** fait partie de la catégorie des algorithmes « diviser pour régner ». À chaque appel de la fonction tri on choisit une valeur « **pivot** », par exemple le premier élément. On effectue une partition



des élément à trier. Un premier groupe est constitué de valeurs inférieures au pivot et un deuxième avec les valeurs supérieures. Le pivot est alors placé définitivement dans le tableau.

On traite alors chacun des groupes de façon indépendante. On peut les traiter avec le même algorithme.

### 3.2 Implémentation

Pour trier une liste, on procède ainsi:

- si la liste est vide, on renvoie la liste vide;
- sinon:
  - on choisit un « pivot », à savoir une valeur de la liste. Dans notre cas, nous prendrons le dernier élément,
  - on crée une liste el\_inf constituée des éléments strictements inférieurs au pivot,
  - on crée une liste el\_sup constituée des éléments supérieurs ou égaux au pivot (en excluant la dernière valeur du tableau, ie le pivot),
  - on renvoie la concatanation du tri rapide appliqué à el\_inf, du pivot ry du tri rapide appliqué à el\_sup.

```
def elts_inf(L : list, p : int) -> list :
   Fonction renvoyant la liste des éléments de L stictements inférieurs àp.
   res = []
   for e in L:
       if e < p:
          res.append(e)
   return res
def elts_sup(L : list, p : int) -> list :
   Fonction renvoyant la liste des éléments de L supérieurs ou égaux àp.
   res = []
   for e in L:
       if e \ge p:
          res.append(e)
   return res
def tri_rapide(L : list) -> list :
   print(L)
   if len(L) == 0:
       return []
       p = L[-1]
       ei = elts_inf(L,p)
       es = elts_sup(L[:-1],p)
       return tri_rapide(ei) + [p] + tri_rapide(es)
```

### 3.3 Terminaison

Prenons comme variant la longueur n de la liste à trier. Nous cherchons à trier des listes de tailles supérieure à n. Initialement, L est de taille n supérieur ou égal à 1. n est un entier strictement positif.

Considérons qu'au début du ième appel de tri\_rapide Li est de taille ni strictement positif.

ei est de taille strictement inférieure à Li car elle ne contient que les valeurs strictement inférieures au pivot. es est de taille strictement inférieure à Li car elle ne contient que les valeurs supérieures ou égales au pivot, à

l'exception du pivot lui-même.

L'appel à tri\_rapide se fait alors sur des listes de tailles strictement inférieures à Li.

n est donc un variant de boucle et la fonction termine.

### 3.4 Correction

Montrons la propriété suivante : « si L une liste de taille inférieure ou égale à n alors tri\_rapide(L) renvoie une liste triée ».

Initialisation La propriété de récurrence est vraie pour une liste vide et pour une liste de taille 1.

**Hérédité** Soit une liste de taille n+1. Le pivot est alors L[-1]. ei et es ont une taille inférieure ou égale à n. D'après la proprité de récurrence, tri\_rapide(ei) et tri\_rapide(es) trient donc ei et es.

De plus, tri\_rapide(ei) + [p] + tri\_rapide(es) renvoie une liste triée.

La propriété de récurrence est donc vraie pour une liste de taille n+1.



### 3.5 Complexité

### Propriété Efficacité de l'algorithme

Cette méthode de tri est très efficace lorsque les données sont distinctes et non ordonnées. La complexité est alors globalement en  $O(n \ln(n))$ . Lorsque le nombre de données devient petit (<15) lors des appels récursifs de la fonction de tri, on peut avantageusement le remplacer par un tri par insertion dont la complexité est linéaire lorsque les données sont triées ou presque. [**Beynet**]

• D'autre part si le tableau est déjà trié avec le code mis en place on tombe sur la complexité « dans le pire des cas ». Une solution simple consiste à ne pas choisir systématiquement le premier élément du segment comme pivot, mais plutôt un élément au hasard. On peut par exemple choisir la valeur de façon aléatoire. [wack]

meilleur cas	pire cas
$n \log n$	$n^2$

Pour un tableau de longueur n:

- on crée une liste ei avec k éléments et une liste es avec n-k-1 éléments (le dernier élément étant le pivot);
- la création de chacune de ces listes fait appel à n comparaisons (boucles for qui itèrent sur chaque élément de L);
- on appelle alors récursivement la fonction tri\_rapide avec les listes de tailles précitées.

Le nombre de comparaisons à l'itération n est donc approximativement de : C(n) = 2n + C(k) + C(n - k - 1).

Dans le pire des cas, k = 0 (ou k = n - 1). En conséquences, C(n) = 2n + C(0) + C(n - 1). Pour une liste de taille 0 ou 1, l'algorithme de tri est réalisé en un tant constant C(0) = C(1) = 1.

On a donc  $C(n) = 2n + 1 + C(n-1) \Leftrightarrow C(n) - C(n-1) = 2n + 1$ . De même à l'itération i, on a C(i) - C(i-1) = 2i + 1. Par sommation, on a alors

$$\sum_{i=1}^{n} (C(i) - C(i-1)) = \sum_{i=1}^{n} (2i+1) \Rightarrow C(n) - C(0) = 2 \times \frac{1}{2} n(n+1) + n \Rightarrow C(n) = n^2 + 2n - 1 = \mathcal{O}(n^2).$$

### 4 Tri fusion – Merge sort

### 4.1 Principe

Cet algorithme fait aussi partie des algorithmes « diviser pour régner ».

Le principe consiste à couper le tableau de départ en deux. On trie chacun des groupes indépendamment. Puis on fusionne les deux groupes en utilisant le fait que chacun des groupe est déjà ordonné.

Il est possible pour réaliser l'ordonnancement de chacun des groupes d'utiliser à nouveau l'algorithme de tri de façon récursive.

### 4.2 Implémentation

Le tri fusion d'une liste se base sur le principe suivant :

- 1. on sépare la liste en 2 listes de longueurs quasi-égales (à un élément près);
- 2. on trie ces deux listes en utilisant le tri fusion (par un appel récursif);
- 3. à partir de deux listes triées, on les fusionne en une seule liste en conservant l'ordre croissant.

```
def separe(L: list) -> tuple[list,list]:
   return L[:len(L) // 2], L[len(L) // 2:]
def fusion(L1: list, L2: list) -> list:
   Fusion de deux listes triées.
   if not L1 or not L2: # si l'une des listes est vide (éventuellement les 2)
       return L1 or L2 # alors on renvoie l'autre (éventuellement vide aussi)
       a, b = L1[0], L2[0]
       if a < b : # sinon on compare leurs premiers éléments
          return [a] + fusion(L1[1:], L2) # on place le plus petit en tête et on fusionne le 🗸
               reste
       else:
          return [b] + fusion(L1, L2[1:])
def tri_fusion(L: list) -> list:
   if len(L) < 2: # cas d'arrêt
       return L
   L1, L2 = separe(L) # sinon on sépare
```



return fusion(tri\_fusion(L1), tri\_fusion(L2)) # et on fusionne les sous-listes triées

#### 4.3 Terminaison

Terminaison de la fusion Soit la suite définie par la somme successive des longueur de L1 et L2.

À chaque itération on appelle fusion à des listes dont la taille d'une d'entre elle est diminuée de 1. La somme des longueurs est donc une suite d'entiers strictement décroissante.

La somme des longueurs est donc un vairant de boucle et la fonction termine.

#### Terminaison du tri

Le tri fusion termine si les listes ont 0 ou 1 éléments. On note  $(u_n)$  la suite définie par  $u_0 = n$ , taille de la liste à trier et  $u_i$  longueur de la plus grande des listes. À chaque étape, la taille des listes est divisé par 2; donc  $u_{i+1} = \left\lfloor \frac{u_i+1}{2} \right\rfloor$ . En conséquence,  $u_{i+1} < u_i$  tant que  $u_i > 1$ . La fonction tri\_fusion termine donc.

### 4.4 Correction

#### 4.5 Complexité

**Propriété** Efficacité de l'algorithme La complexité est  $n \log(n)$ 

meilleur cas	pire cas
$n \log n$	$n \log n$

#### 4.5.1 Complexité du tri fusion – Petites remarques

Quel est le coût de l'algorithme de fusion présenté précédemment? En Python, concaténer deux listes nécessite de copier ces deux listes dans une nouvelle liste. Cette opération est donc en  $\mathcal{O}(n)$ .

Par ailleurs, la taille des listes à concaténer diminue de 1 à chaque itération. Il y aura donc n appels récursifs. L'algorithme de fusion présenté est donc en  $\mathcal{O}(n^2)$ .

La séparation quant à elle est complexité  $\mathcal{O}\log_2(n)$  (en effet, le nombre de fois que fois qu'on peut diviser notre liste de taille n en 2 listes de taille n/2 est à peu près de  $\log(n)$ .

L'algorithme proposé est donc en  $\mathcal{O}(n^2 \log(n))$ ... et pas en  $n \log(n)$ !

Il faudrait donc rechercher un algorithme de fusion de complexité linéaire...

#### 4.5.2 Exemple de fusion linéaire...

```
def fusion(L1,L2):
   n1 = len(L1)
   n2 = len(L2)
   L12 = [0]*(n1+n2)
   i1 = 0
   i2 = 0
   i = 0
   while i1 < n1 and i2 < n2:
       if L1[i1] < L2[i2]:
           L12[i] = L1[i1]
           i1 += 1
           L12[i] = L2[i2]
           i2 += 1
       i += 1
   while i1<n1:
       L12[i] = L1[i1]
       i1 += 1
        i += 1
   while i2 < n2:
       L12[i] = L2[i2]
        i2 += 1
       <u>i</u> += 1
    return L12
```

### 5 Dans Python : sort et sorted

Les listes Python ont une méthode native list.sort() qui modifie les listes elles-mêmes et renvoie None.



## 6 Conclusion et méthodes dans Python

**Propriété** Distinguer par leurs complexités deux algorithmes résolvant un même problème :


La première étape consiste à vérifier que les algorithmes résolvent exactement le même problème.

- On compare la complexité en temps dans le pire des cas (préférable a l'utilisation du module Time comme ci dessous car indépendant de la machine).
- Il faut vérifier que le pire des cas peut arriver en situation réelle
- Penser à comparer la complexité en espace qui peut permettre de départager des algorithmes équivalents



# Exemple 1 : Illustration de la comparaison

Pour comparer les temps globaux sur une même machine (Ici processeur Intel Core i7-4510U Haswell (2 GHz, TDP 15W), Mémoire vive 4 Go) on génère des tableaux de dimensions différentes avec des nombres aléatoires. On utilise le module time pour déterminer les temps. Ici c'est un temps global dépendant fortement de la machine utilisée. On fait varier la taille du tableau et on compare les temps mis par chacun des algorithmes (en rouge tri rapide, en bleu tri insertion, en vert tri fusion).



### Références

- [1] Irène Charon Olivier Hudry, Algorithmes de tri, cours de Télécom ParisTech, Avril 2014.
- [2] B. Wack, S. Conchon, J. Courant, M. de Falco, G. Dowek, J.-C. Filliâtre, S. Gonnord, Informatique pour tous en classes préparatoires aux grandes écoles. Manuel d'algorithmique et programmation structurée avec Python. Nouveaux programmes 2013. Voies MP, PC, PSI, PT, TPC et TSI, Eyrolles, 2013.
- [3] Beynet Patrick, Cours d'informatique publié sur le site de l'UPSTI.

### 7 QCM

**Question 1** On dispose d'une liste de triplets: t = [(1,12,250),(1,12,251),(2,12,250),(2,13,250),(2,11,250),(2,12,250),(2,13,250),(2,11,250),(2,12,250),(2,13,250),(2,11,250),(2,12,250),(2,13,250),(2,11,250),(2,12,250),(2,13,250),(2,11,250),(2,12,250),(2,13,250),

**Question 1** On dispose d'une liste de triplets :  $t = \begin{bmatrix} 2 & (2,11,250), (1,12,249), (1,12,250), (2,1$ 

4. [(1,12,249),(2,11,250),(1,12,250),(2,12,250),(2,

**Question 2** Quelle valeur retourne la fonction mystere suivante?



- 1. Une valeur booléenne indiquant si la liste liste passée en paramètre est triée.
- 2. La valeur du plus grand élément de la liste passée en paramètre.
- 3. La valeur du plus petit élément de la liste passée en paramètre.
- 4. Une valeur booléenne indiquant si la liste passée en paramètre contient plusieurs fois le même élément.

**Question 3** Combien d'échanges effectue la fonction Python suivante pour trier un tableau de 10 éléments au pire des cas?

```
def tri(tab) :
    for i in range (1, len(tab)) :
        for j in range (len(tab) - i) :
        if tab[j] > tab[j+1] :
        tab[j], tab[j+1] = tab[j/
        +1], tab[j]
```

- 1. 45.
- 2. 100.
- 3. 10.
- 4. 55.

**Question 4** Que vaut l'expression f ([7, 3, 1, 8, 19, 9, 3, 5], 0)?

```
def f(t,i) :
    im = i
    m = t[i]
    for k in range(i+1, len(t)) :
        if t[k] < m :
            im, m = k, t[k]
    return im</pre>
```

- 1. 1.
- 2. 2.
- 3. 3.
- 4. 4.

**Question 5** Laquelle de ces listes de chaînes de caractères est triée en ordre croissant?

```
1. ['Chat', 'Cheval', 'Chien', 'Cochon'].
2. ['Cochon', 'Chat', 'Cheval', 'Chien'].
3. ['Cheval', 'Chien', 'Chat', 'Cochon'].
4. ['Chat', 'Cochon', 'Cheval', 'Chien'].
```

**Question 6** Laquelle de ces listes de chaînes de caractères est triée en ordre croissant?

```
1. ['12','142','21','8'].
2. ['8','12','142','21'].
3. ['8','12','21','142'].
4. ['12','21','8','142'].
```

**Question 7** Quelle est la valeur de la variable table après exécution du programme Python suivant?

```
table = [12, 43, 6, 22, 37]
for i in range(len(table) - 1):
    if table [i] > table [i+1] :
        table [i] ,table [i+1] = table [i+1] ,/
        table [i]
```

- 1. [12, 6, 22, 37, 43].
- 2. [6, 12, 22, 37, 43].
- 3. [43, 12, 22, 37, 6].
- 4. [43, 37, 22, 12, 6].

**Question 8** *Un algorithme cherche la valeur maximale d'une liste non triée de taille n. Combien de temps mettra cet algorithme sur une liste de taille 2n ?* 

- 1. Le même temps que sur la liste de taille n si le maximum est dans la première moitié de la liste.
- 2. On a ajouté *n* valeurs, l'algorithme mettra donc n fois plus de temps que sur la liste de taille *n*.
- 3. Le temps sera simplement doublé par rapport au temps mis sur la liste de taille *n*.
- 4. On ne peut pas savoir, tout dépend de l'endroit où est le maximum.

**Question 9** *Quel est le coût en temps dans le pire des cas du tri par insertion?* 

- 1.  $\mathcal{O}(n)$ .
- 2.  $\mathcal{O}(n^2)$ .
- 3.  $\mathcal{O}(2^n)$ .
- 4.  $\mathcal{O}(\log n)$ .